

Implementação de Funções Lógicas utilizando retropropagação do erro

Bruno Gomes Cordeiro¹

Kênya Magalhães dos Santos²

Fábio Henrique M. Oliveira³

RESUMO

Este artigo apresenta a implementação de funções lógicas e análise de uma Rede Neural Artificial Multicamada (MultiLayer Perceptron – MLP) desenvolvida em linguagem Python para a resolução da função lógica XOR, utilizando o algoritmo de Retropropagação do Erro (Backpropagation). Inicialmente, são abordados os conceitos fundamentais das redes neurais artificiais, sua estrutura em camadas e a importância das funções de ativação na resolução de problemas não linearmente separáveis. A pesquisa possui abordagem quantitativa e caráter experimental, avaliando o comportamento da rede diante de diferentes configurações de hiperparâmetros. A implementação foi realizada manualmente, sem o uso de frameworks de aprendizado de máquina, empregando as bibliotecas NumPy e Matplotlib para cálculos numéricos e visualização dos resultados. Os experimentos demonstraram que a MLP foi capaz de aprender corretamente a função XOR, evidenciando a necessidade de uma camada oculta para problemas não linearmente separáveis e a influência significativa dos hiperparâmetros no desempenho do treinamento. Os resultados obtidos validam os conceitos teóricos apresentados na literatura e contribuem para a compreensão prática do funcionamento interno das redes neurais artificiais e do aprendizado supervisionado.

Palavras-chave: Redes Neurais Artificiais; Multiplayer Perceptron; Backpropagation; XOR; Aprendizado Supervisionado; Python.

¹ Graduando em Tecnologia em Sistemas para Internet no Instituto Federal de Ciência, Tecnologia e Educação de Brasília - Campus Brasília. E-mail: bruno63072@estudante.ifb.edu.br

² Graduanda em Tecnologia em Sistemas para Internet no Instituto Federal de Ciência, Tecnologia e Educação de Brasília - Campus Brasília. E-mail: kenya51498@estudante.ifb.edu.br

³ Bacharel em Sistemas de Informação, Doutor em Engenharia Elétrica com ênfase em Engenharia Biomédica e Professor do Instituto Federal de Ciência, Tecnologia e Educação de Brasília – Campus Brasília. E-mail: fabio.oliveira@ifb.edu.br

RESUMO EM LÍNGUA ESTRANGEIRA

This article presents the implementation of logical functions and an analysis of a Multi-Layer Perceptron (MLP) developed in Python to solve the XOR logical function using the Backpropagation algorithm. Initially, the fundamental concepts of artificial neural networks, their layered structure, and the importance of activation functions in solving non-linearly separable problems are addressed. The research employs a quantitative and experimental approach, evaluating the network's behavior under different hyperparameter configurations. The implementation was performed manually, without the use of machine learning frameworks, employing the NumPy and Matplotlib libraries for numerical calculations and visualization of the results. The experiments demonstrated that the MLP was able to correctly learn the XOR function, highlighting the need for a hidden layer for non-linearly separable problems and the significant influence of hyperparameters on training performance. The results obtained validate the theoretical concepts presented in the literature and contribute to the practical understanding of the inner workings of artificial neural networks and supervised learning.

Keywords: Artificial Neural Networks; Multi-Layer Perceptron; Backpropagation; XOR; Supervised Learning; Python.

1. INTRODUÇÃO

As redes neurais são sistemas inteligentes que funcionam como um cérebro eletrônico ensinado para imitar a maneira como o ser humano aprende a resolver problemas. Elas são inspiradas no próprio cérebro humano, essas redes são formadas por unidades de processamento conhecidas como neurônios artificiais, que são conectados por pesos sinápticos que guardam o conhecimento adquirido no período do treinamento.

Existem vários modelos, mas as redes multicamadas (MultiLayer Perceptron – MLP) tem um destaque importante pela sua habilidade em resolver problemas não linearmente separáveis através da utilização de uma ou mais camadas de neurônios artificiais. O seu treinamento é realizado por meio do algoritmo de Retropropagação de Erro (Backpropagation), responsável por adaptar repetidamente os pesos da rede de forma a diminuir o erro entra a saída produzida e a saída esperada.

2. FUNDAMENTAÇÃO TEÓRICA

Uma rede neural artificial é constituída por um grupo de neurônios artificiais estruturados em camadas, que dialogam entre si através de conexões medidas por pesos. Por meio do seu ensinamento, esses pesos são ajustados de forma que a rede aprenda uma determinada função ou padrão.

O modelo Multiplayer Perceptron (MLP) é composto por uma camada de entrada, uma ou mais camadas intermediárias e uma camada de saída. A existência das camadas intermediárias permite resolver questões que não podem ser separadas por uma única fronteira linear. Segundo Oliveira e Braga(2011) a solução de problemas não linearmente separáveis passa pelo uso de redes com uma ou mais camadas intermediárias.

No caso do algoritmo Backpropagation ele é um método acompanhado e inspirado no gradiente descendente. O seu funcionamento ocorre por meio de duas etapas principais que são: Forward propagação dos dados da entrada até a saída da rede e Backward que é o cálculo do erro e a atualização dos pesos através da retropropagação do erro.

Para que toda essa etapa possa acontecer seja possível, são utilizadas as funções de ativação contínuas e diferenciais, sendo as mais comuns:

Sigmoide Binária

$$f(x) = 1 / (1 + e^{(-x)})$$

Sigmoide Bipolar

$$f(x) = 2 / (1 + e^{(-x)}) - 1$$

Tangente Hiperbólica

$$\tanh(x) = (e^x - e^{(-x)}) / (e^x + e^{(-x)})$$

Essas funções de ativação confere não linearidade ao modelo computacional, expandido a capacidade computacional das redes MLP, deixando o modelo próprio para decodificar correlações complexas entre o vetor de entrada e o espaço de saída.

Sobre a questão XOR é um exemplo clássico de problema não linearmente separável e forma uma das principais aplicações educativas para demonstrar a necessidade de redes multicamadas treinadas por Backpropagation.

Tentar separar apenas uma reta separando as classes não é possível; sempre haverá pelo menos um elemento posicionado na região errada.

Isso acontece pelo seguinte:

$$(0,0) \rightarrow \text{classe 0}$$

$(1,1) \rightarrow$ classe 0

Estão em diagonais opostas dos pontos:

$(0,1) \rightarrow$ classe 1

$(1,0) \rightarrow$ classe 1

Não tem uma reta que consiga separar corretamente essas duas classes. Isso explica, porque o problema XOR é considerado não linearmente separável.

3. METODOLOGIA

A presente atividade se caracteriza como uma pesquisa de natureza, usando abordagem quantitativa e de caráter experimental, com o objetivo de implementar e avaliar uma Rede Neural Artificial Multicamadas (MultiLayer Perceptron – MLP) para a resolução da função lógica XOR através do algoritmo de Retropropagação do Erro (Backpropagation).

O modelo computacional foi estruturado como um *Perceptron* Multicamadas (MLP) estruturado com duas entradas, sendo uma camada intermediária com número de neurônios ajustável e uma única variável de saída, normalizada por uma função de ativação sigmoide. De acordo com Gomide(2012) redes Perceptron multicamadas, detalha redes neurais com camadas múltiplas de neurônios e o algoritmo de propagação retroativa (backpropagation).

Além da reprodução do experimento principal proposto na literatura foram estruturados experimentos complementares a fim de avaliar a sensibilidade do modelo frente a diferentes configurações. Essa variação permitiu analisar a influência dessas variáveis no comportamento e no rendimento do processo de treinamento.

4. IMPLEMENTAÇÃO

A implementação foi desenvolvida toda em linguagem Python de forma exclusiva bibliotecas especializadas em computação numérica e síntese de gráficos. Para a manipulação das estruturas vetoriais entradas, pesos e *bias* e execução do cálculo matricial, adotou-se a biblioteca NumPy, ao passo que a biblioteca Matplotlib foi utilizada para a síntese dos gráficos de desempenho do treinamento.

A implementação da Rede Neural Artificial ocorreu de maneira manual mediante a criação da classe MLP. Essa classe concentra a lógica de gerenciamento dos pesos sinápticos e *bias*, além de prover as rotinas operacionais para as etapas de propagação direta, retropropagação do erro, ajuste de parâmetros, treinamento e predição.

Durante a etapa de inicialização, as matrizes de pesos e os vetores de *bias* foram definidos de forma aleatória no intervalo $[-1,1]$. A rede neural foi estruturada sob uma arquitetura de múltiplas camadas (MLP), integrando dois neurônios de entrada, quatro neurônios na camada intermediária e um único neurônio na camada de saída. Na etapa de propagação direta *forward propagation*, realizou-se o produto escalar entre os vetores de entrada e suas respectivas matrizes de pesos, somando-se os *bias*.

O trabalho descreve o desenvolvimento e a análise de uma Rede Neural Multicamadas (MLP) implementada de forma autônoma sem o auxílio de *frameworks* de aprendizado de máquina, visando à compreensão do algoritmo *Backpropagation* e do aprendizado supervisionado.

5.RESULTADOS

Os resultados evidenciaram que o modelo convergiu com sucesso para a resolução da função lógica XOR, demonstrando sensibilidade significativa aos hiperparâmetros adotados. Foi observado que a ampliação do número de neurônios na camada oculta não resulta, necessariamente, no incremento da velocidade de convergência.

6. DISCUSSÃO

Na avaliação comparativa evidenciou que os problemas linearmente separáveis (AND, OR, NAND e NOR) apresentaram alta eficiência computacional, destacando – se por uma acelerada otimização, rápida minimização do erro e baixa exigência de épocas decorrente da simplicidade estrutural de tais funções. Por outro lado, a modelagem da função não linear XOR exigiu, necessariamente, a inserção de uma camada oculta para a projeção do espaço de características. O que resultou em um cenário de otimização de maior complexidade com demanda ampliada por épocas de treinamento e elevada dependência da taxa de aprendizado e à distribuição inicial dos pesos.

7. CONCLUSÃO

Este trabalho mostra detalhadamente a implementação prática e autônoma de uma Rede Neural Multicamadas conhecida por MLP em linguagem Python, utilizando o algoritmo *Backpropagation* para a resolução e análise comparativa de funções lógicas. Os resultados comprovaram que funções linearmente separáveis (AND, OR, NAND, NOR) manifestam uma estabilização precoce do modelo e menor custo algorítmico, ao passo que a função não linear XOR condicionou-se à incorporação de uma camada intermediária para o mapeamento do espaço de características.

Os testes também confirmaram a marcante dependência da rede quanto ao ajuste de seus hiperparâmetros destacando-se variáveis como o passo de aprendizagem, a densidade de neurônios na camada intermediária e a distribuição aleatória dos pesos. Validando empiricamente os conceitos da literatura e consolidando a compreensão acerca do funcionamento interno e do fluxo operacional do aprendizado supervisionado.

REFERÊNCIA

GOMIDE, Fernando A. **Resenha de Livro: Redes Neurais Artificiais para Engenharia e Ciências Aplicadas: curso prático** (Autores: Ivan Nunes da Silva, Danilo Hernane Spatti, Rogério Andrade Flauzino). **Revista Controle & Automação**, v. 23, n. 5, p. 649-652, set./out. 2012.

OLIVEIRA, Fábio Henrique M.; BRAGA, Pedro Henrique C. **Implementação de funções lógicas utilizando retropropagação do erro**. 2011